## Web Crawling e Scraping com Scrapy e Scrapy Cloud

#### >whoami



#### **Lidiane Taquehara**

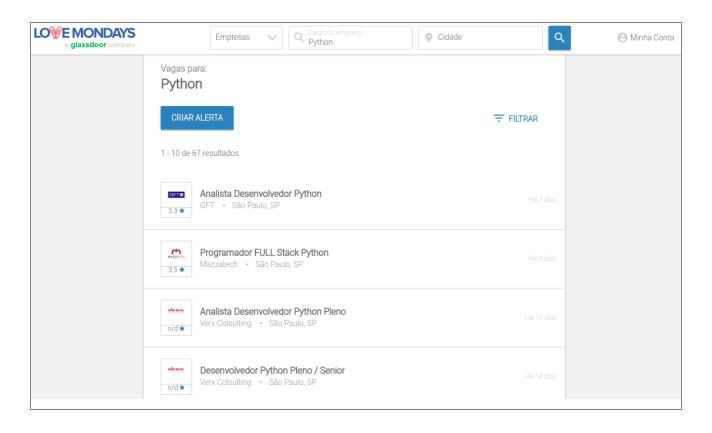


- Tecnóloga em Análise e Desenvolvimento de Sistemas pela FATEC Jundiaí
- Back-end developer na Love Mondays

## Web Scraping

## Web Crawling

### Web Crawling e Scraping no Love Mondays



### **Scrapy**

- Framework Python voltado para scraping e crawling
- Open Source
- Construído em cima do Twisted
  - Eficiente
  - Assíncrono

#### Exemplo de uma Spider

- Acessa a lista dos 100 filmes mais populares no IMDB
- Coleta o título de cada filme
- Acessa a página específica de cada filme
- Coleta também a sinopse e o nome do diretor

Link para o exemplo no GitHub

#### O código

```
name = 'most_popular_movies'
```

O nome que identifica a spider

```
start_urls =
```

```
['https://www.imdb.com/chart/moviemeter']
```

O ponto de partida da spider

```
parse()
```

Método que manipula a resposta recebida por cada requisição feita.

## Execução da spider

# Gerenciamento dos

## dados na nuvem

### Scrapinghub

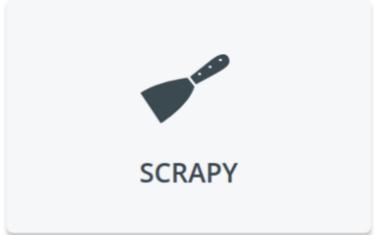
- Criação e manutenção do Scrapy
  - Data on Demand
  - Scrapy Cloud

#### **Scrapy Cloud**

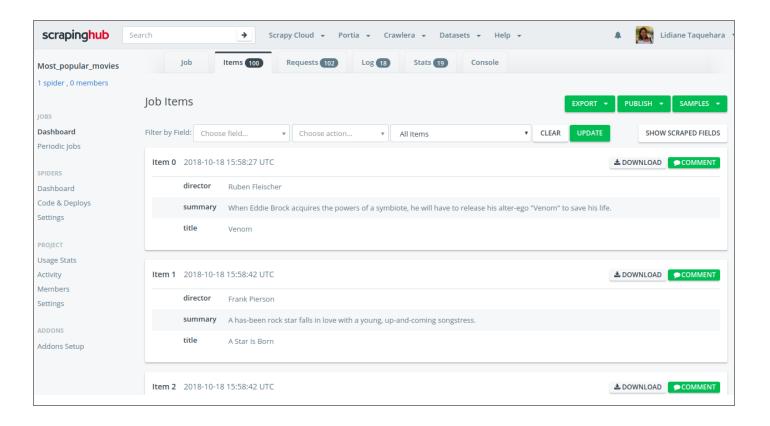
- Execução de web crawling em nuvem
- Armazenamento dos dados em um banco de alta disponibilidade

### **Tecnologias**





#### **Dashboard**



#### Utilização dos dados

#### Possibilidades:

- Download (CSV, JSON JSON Lines, XML)
- Publicação como um dataset público no Scrapinghub
- Consumo dos dados através da Scrapy Cloud API

#### **Scrapy Cloud API**

- Permite interagir com as spiders e os dados coletados.
- Endpoints:
  - app.scrapinghub.com
  - storage.scrapinghub.com

### python-scrapinghub

- Client Python: python-scrapinghub
- Exemplo simples: https://github.com/lidimayra/scrapinghub-api-demo

#### Para saber mais:

- Scrapy Site oficial
- Scrapy GitHub
- Scrapinghub Site oficial
- Scrapinghub GitHub

#### Muito obrigada!!

Apresentação disponível em:

https://scrapy-slides.netlify.com